



Universidad Peruana de Ciencias Aplicadas

Curso
Data Visualization

Tema
Análisis del comportamiento de ventas en retail para la optimización de decisiones
comerciales mediante visualización de datos

Docente
Carlos Adrian Alarcon Delgado

Integrantes

Código	Apellido	Nombres
u20191c439	Miranda Cardenas	Sofía Gabriel
u201616851	Olivera Alvarez	Lizbeth Teresita
U20221C621	Gomez Rubina	Luis David

Contenido

1. Caso de análisis.....	3
2. Ficha técnica del proyecto.....	3
3. Pregunta analítica principal.....	3
4. Problema.....	4
5. Justificación de Valor del proyecto.....	4
6. Usuario objetivo.....	4
7. Conjunto de datos.....	5
a. Potencial del Dataset.....	6
b. Riesgo del Dataset.....	6
8. hipótesis iniciales.....	6
9. Limpieza de los datos.....	7
10. Perfilado de los datos.....	12
11. Bitácora de transformaciones.....	14
12. EDA.....	15
13. Insights.....	27
Insight 1 : Las regiones West y East impulsan el desempeño comercial del negocio.....	27
Insight 2 : La categoría Technology presenta el mayor impacto en las ventas.....	27
Insight 3 : Las ventas presentan patrones estacionales durante el cuarto trimestre.....	28
Insight 4 : La frecuencia de transacciones no siempre implica mayores ingresos.....	28
Insight 5 : Los tiempos de envío presentan estabilidad y baja influencia sobre las ventas.....	28
14. Gráficos descartados.....	28
15. Reglas de Métricas, Segmentos y Parámetros.....	29
15.1. Estructura analítica para Tableau.....	29
15.2. Segmento definido.....	29
15.3. Métricas derivadas y su relación con la pregunta analítica.....	30
15.4. Parámetros y lógica analítica para Tableau.....	31
15.5. Fuentes finales para Tableau.....	31
15.6. Evidencia de validación ejecutada.....	32
16. Conclusiones.....	32
17. Referencias.....	33
Anexos.....	34


1. Caso de análisis

El presente proyecto analiza el comportamiento de ventas de un superstore a partir de un dataset público obtenido de la plataforma Kaggle (Sahoo, 2020).

El dataset contiene información histórica de transacciones comerciales, incluyendo variables como fechas de pedido, categorías de productos, ubicación geográfica y montos de ventas.

El análisis se enfoca en comprender cómo evolucionan las ventas en el tiempo y cómo factores como la categoría de producto y la región influyen en su comportamiento, con el objetivo de generar insights que apoyen la toma de decisiones.

2. Ficha técnica del proyecto



Link para mejor visualización	https://app.powerbi.com/links/CV7HkrDRkM?ctid=0e0cb060-09ad-49f5-a005-68b9b49aa1f6&pbi_source=linkShare
-------------------------------	---

3. Pregunta analítica principal

¿Qué patrones estacionales y diferencias regionales en el desempeño de las categorías influyen en las ventas y cómo pueden utilizarse para apoyar la toma de decisiones del negocio?

4. Problema

En el sector retail, muchas decisiones comerciales se toman sin un análisis estructurado de los datos históricos de ventas. Esto genera dificultades como:

- Falta de previsión de la demanda
- Ineficiencia en la gestión de inventarios
- Dificultad para identificar productos o regiones con mejor desempeño

Además, la ausencia de herramientas de visualización adecuadas limita la identificación de patrones y tendencias relevantes.

5. Justificación de Valor del proyecto

Este proyecto tiene como objetivo aportar valor mediante el uso de técnicas de visualización de datos que permitan:

- Identificar patrones de comportamiento en las ventas
- Detectar tendencias temporales y estacionales
- Comparar el rendimiento entre categorías y regiones
- Facilitar el análisis del desempeño comercial

Asimismo, se incorpora un enfoque de análisis geográfico a partir de variables como región, estado y ciudad, lo que permite identificar diferencias en el desempeño del negocio según ubicación.

El proyecto busca facilitar la toma de decisiones basada en datos, especialmente en aspectos relacionados con la planificación comercial y la gestión de inventario. Y el uso de herramientas como Tableau permitirá construir dashboards interactivos que comuniquen los resultados de forma clara y accesible para los usuarios del negocio.

6. Usuario objetivo

El usuario objetivo del proyecto es un gerente de ventas responsable de supervisar el desempeño comercial del negocio.

Este usuario requiere herramientas que le permitan:

- Monitorear las ventas en el tiempo
- Identificar qué productos o categorías generan mayor ingreso
- Analizar el rendimiento por región
- Detectar oportunidades de mejora

El dashboard será utilizado en revisiones periódicas (mensuales) para evaluar el desempeño de ventas y comparar resultados entre regiones y categorías.

El dashboard desarrollado permitirá analizar el desempeño de ventas de forma objetiva, basada en datos, en lugar de intuición.

7. Conjunto de datos

El dataset seleccionado corresponde a un conjunto de datos de ventas de un superstore, disponible en Kaggle.

Características principales:

- Aproximadamente 9800 registros
- Más de 10 variables relevantes
- Incluye dimensiones:
 - Temporal (fecha de pedido)
 - Categórica (categoría, subcategoría)
 - Geográfica (región, estado)
 - Numérica (ventas, entre otras)

Tabla 1.

Descripción de variables

Variable	Descripción
Row ID	Identificador único de cada registro o fila
Order ID	Identificador único de cada pedido
Order Date	Fecha en que se realizó el pedido
Ship Date	Fecha en que se envió el pedido
Ship Mode	Tipo de envío utilizado
Customer ID	Identificador único del cliente
Customer Name	Nombre del cliente
Segment	Segmento de cliente (tipo de mercado)
Country	País del cliente
City	Ciudad del cliente
State	Estado del cliente
Postal Code	Código postal del cliente
Region	Región geográfica

Product ID	Identificador único del producto
Category	Categoría principal del producto
Sub-Category	Subcategoría del producto
Product Name	Nombre del producto
Sales	Monto total de ventas por registro

En esta esta parte se le adjunta el link de donde se consiguió el dataset.

link del dataset en Kaggle	https://www.kaggle.com/datasets/rohitsahoo/sales-forecasting?resource=download
----------------------------	---

a. Potencial del Dataset

El dataset presenta un alto potencial analítico debido a que permite:

- Analizar tendencias de ventas a lo largo del tiempo.
- Realizar comparaciones entre categorías de productos.
- Evaluar el desempeño por regiones geográficas.
- Construir indicadores clave de rendimiento (KPIs).
- Aplicar técnicas de análisis exploratorio y visualización.

Además, es adecuado para la construcción de dashboards en Tableau y análisis complementario en Python.

b. Riesgo del Dataset

Se identifican los siguientes posibles riesgos:

- Presencia de valores nulos o inconsistentes.
- Limitación en variables externas (no incluye factores como promociones o condiciones del mercado).
- Representatividad limitada a un solo tipo de negocio.
- Posible necesidad de transformación para análisis temporal.

8. hipótesis iniciales

Se plantean las siguientes hipótesis para guiar el análisis:

1. Las ventas presentan patrones estacionales a lo largo del tiempo.
2. Existen diferencias significativas en las ventas entre categorías de productos.
3. Las regiones geográficas influyen en el volumen de ventas.
4. Se pueden identificar tendencias de crecimiento o decrecimiento en ciertos periodos.
5. El comportamiento histórico de las ventas permite estimar patrones futuros.

9. Limpieza de los datos

El objetivo principal de este proceso fue asegurar la calidad, consistencia e integridad del dataset `data__train`, dejándolo en un estado óptimo para el análisis exploratorio de datos (EDA) y la modelización posterior. Se abordaron problemas comunes como valores nulos, formatos incorrectos de datos y estandarización de texto. El dataset original, cargado desde [/content/train.csv](#), contiene información transaccional detallada, incluyendo datos de pedidos, clientes, productos y ventas.

a. Identificación de Problemas Iniciales:


- **Valores Nulos:** Se identificaron 11 valores nulos en la columna `Postal Code` (0.11% del total).
- **Tipos de Datos:** Las columnas de fecha (`Order Date`, `Ship Date`) fueron inicialmente importadas como `object` (string), requiriendo conversión a formato `datetime`.
- **Consistencia de Texto:** Algunas columnas categóricas (`City`, `State`, `Category`, `Sub-Category`, `Segment`) podrían contener inconsistencias en el formato de texto (espacios extra, capitalización variada).
- **Duplicados:** Se realizó una verificación para identificar filas completamente duplicadas.

b. Pasos de Limpieza y Transformación:

Manejo de Valores Nulos en `Postal Code`:

Se convirtió la columna `Postal Code` a tipo de dato `Int64` (permitiendo valores nulos enteros) y luego a `str` para un manejo uniforme. Este proceso fue un paso intermedio para asegurar la correcta lectura y manipulación de los códigos postales que podrían ser tratados como valores numéricos o texto. Finalmente, los valores nulos (`nan` o `<NA>`) fueron reemplazados por la cadena "Desconocido". Esta estrategia permite retener todos los registros sin perder información útil, aunque se reconoce que `Postal Code` no es una variable clave para el análisis de caso principal.


Ilustración 1.



```
1 data_train.isnull().sum()
2 # 11 DATOS FALTANTES EN POSTAL CODE
```

...	0
Row ID	0
Order ID	0
Order Date	0
Ship Date	0
Ship Mode	0
Customer ID	0
Customer Name	0
Segment	0
Country	0
City	0
State	0
Postal Code	11
Region	0
Product ID	0
Category	0
Sub-Category	0
Product Name	0
Sales	0

Ilustración 2.




```
'2151', '77301', '60477', '52001', '48127', '87505', '28601',  
1 data_train["Postal Code"] = data_train["Postal Code"].replace(["nan", "<NA>"], "Desconocido")  
2 data_train["Postal Code"].unique()  
array(['42420', '90036', '33311', '90032', '28027', '98103', '76106',  
      '53711', '84084', '04100', '68025', '10140', '84057', '00040',
```

Conversión de Tipos de Datos de Fecha:

Las columnas Order Date y Ship Date fueron convertidas exitosamente al tipo datetime64 utilizando pd.to_datetime. Esto es crucial para realizar operaciones temporales y crear nuevas variables basadas en el tiempo.

Ilustración 3.



```
1 # CORREGIR LAS FECHAS  
2 data_train['Order Date'] = pd.to_datetime(data_train['Order Date'], dayfirst=True, format='%m/%d/%Y')  
3 data_train['Ship Date'] = pd.to_datetime(data_train['Ship Date'], dayfirst=True, format='%m/%d/%Y')
```

Estandarización de Variables Categóricas:

Las columnas City, State, Category, Sub-Category, y Segment fueron estandarizadas aplicando `str.strip().str.title()`. Esto eliminó espacios en blanco redundantes y uniformó la capitalización (primera letra en mayúscula), mejorando la consistencia para el agrupamiento y análisis.

Ilustración 4.

```
Estandarización

1 cols = ["City", "State", "Category", "Sub-Category", "Segment"]
2
3 for col in cols:
4     data__train[col] = data__train[col].str.strip().str.title()
```

Verificación de Duplicados:

Se confirmó que el dataset no contiene filas completamente duplicadas, lo que indica que cada registro es único en su combinación de valores.

Ilustración 5.

```
DUPLICADOS

1 data__train.duplicated().sum() #NO CUENTA CON DUPLICADOS
np.int64(0)
```

Creación de Nuevas Variables (Feature Engineering):

Nivel_Ventas: Se creó una variable categórica (Bajo, Medio, Alto) a partir de la columna Sales utilizando `pd.qcut` para segmentar las ventas en terciles.

Variables Temporales: Se extrajeron Year, Month, Month_Name y Quarter de Order Date para facilitar el análisis temporal y la identificación de patrones estacionales.

Region_Category: Se combinaron las columnas Region y Category para crear una nueva variable categórica que representa la interacción entre la ubicación geográfica y la categoría de producto.

Shipping_Time: Se calculó el tiempo de envío en días restando Order Date de Ship Date.

Ilustración 6.

```
***   Order Date  Ship Date  Year  Month  Month_Name  Quarter  \
0  2017-11-08  2017-11-11  2017    11    November  2017Q4
1  2017-11-08  2017-11-11  2017    11    November  2017Q4
2  2017-06-12  2017-06-16  2017     6         June  2017Q2
3  2016-10-11  2016-10-18  2016    10    October  2016Q4
4  2016-10-11  2016-10-18  2016    10    October  2016Q4

      Region_Category  Shipping_Time
0      South - Furniture              3
1      South - Furniture              3
2      West - Office Supplies          4
3      South - Furniture              7
4      South - Office Supplies          7

Nulos por columna relevante:
Order Date      0
Ship Date       0
Year            0
Month           0
Quarter         0
Shipping_Time    0
dtype: int64
```

Identificación de Outliers:

Se realizó un análisis de outliers en la columna Sales utilizando el método del rango intercuartílico (IQR). Se identificaron 1145 outliers. Si bien no fueron eliminados en esta fase de limpieza, su presencia se ha documentado para consideración en etapas de análisis más profundas, donde podrían requerir un tratamiento específico dependiendo del objetivo.

Ilustración 7.




Ilustración 8.

```
1 # Calcular cuartiles
2 Q1 = data_train["Sales"].quantile(0.25)
3 Q3 = data_train["Sales"].quantile(0.75)
4
5 # Calcular IQR
6 IQR = Q3 - Q1
7
8 # Límites
9 lim_inf = Q1 - 1.5 * IQR
10 lim_sup = Q3 + 1.5 * IQR
11
12 # Filtrar outliers
13 outliers = data_train[(data_train["Sales"] < lim_inf) | (data_train["Sales"] > lim_sup)]
14
15 # Cantidad de outliers
16 print("Cantidad de outliers:", len(outliers))
```

Cantidad de outliers: 1145

- c. **Estado Final del Dataset:** Tras la aplicación de los pasos de limpieza, el dataset `data__train`:
- No contiene valores nulos en ninguna de sus 26 columnas.
 - Las columnas de fecha están correctamente tipadas como `datetime`.
 - Las columnas categóricas están estandarizadas.
 - Se han añadido 8 nuevas variables enriquecedoras.
 - Las dimensiones del dataset son 9800 filas y 26 columnas.

Ilustración 9.

```
1 data__train.info()
```

```
... <class 'pandas.core.frame.DataFrame'>
RangeIndex: 9800 entries, 0 to 9799
Data columns (total 26 columns):
 #   Column              Non-Null Count  Dtype
---  -
 0   Row ID              9800 non-null  int64
 1   Order ID            9800 non-null  object
 2   Order Date          9800 non-null  datetime64[ns]
 3   Ship Date           9800 non-null  datetime64[ns]
 4   Ship Mode           9800 non-null  object
 5   Customer ID         9800 non-null  object
 6   Customer Name       9800 non-null  object
 7   Segment             9800 non-null  object
 8   Country             9800 non-null  object
 9   City                9800 non-null  object
10   State               9800 non-null  object
11   Postal Code         9800 non-null  object
12   Region              9800 non-null  object
13   Product ID          9800 non-null  object
14   Category            9800 non-null  object
15   Sub-Category        9800 non-null  object
16   Product Name        9800 non-null  object
17   Sales               9800 non-null  float64
18   Year                9800 non-null  int32
19   Month               9800 non-null  int32
20   Month Name          9800 non-null  object
21   Nivel_Ventas        9800 non-null  category
22   Month_Name          9800 non-null  object
23   Quarter             9800 non-null  object
24   Region_Category     9800 non-null  object
25   Shipping_Time       9800 non-null  int64
dtypes: category(1), datetime64[ns](2), float64(1), int32(2), int64(2), object(18)
memory usage: 1.8+ MB
```

- d. Diccionario de datos del dataset limpio

Tabla 2.

Descripción de variables del dataset procesado.

Columna	Tipo de Dato	Descripción
Row ID	int64	Identificador único para cada fila o registro de la transacción
Order ID	object	Identificador único para cada orden de compra
Order Date	datetime64	Fecha en la que se realizó la orden
Ship Date	datetime64	Fecha en la que se envió el producto
Ship Mode	object	Modo de envío utilizado (e.g., Second Class, Standard Class)
Customer ID	object	Identificador único del cliente
Customer Name	object	Nombre del cliente
Segment	object	Segmento de mercado del cliente (e.g., Consumer, Corporate)
Country	object	País donde se realizó la orden
City	object	Ciudad donde se realizó la orden
State	object	Estado donde se realizó la orden
Postal Code	object	Código postal de la ubicación de la orden
Region	object	Región geográfica de la orden
Product ID	object	Identificador único del producto
Category	object	Categoría principal del producto (Furniture, Technology, etc.)
Sub-Category	object	Subcategoría del producto
Product Name	object	Nombre del producto
Sales	float64	Monto total de ventas por transacción
Year	int32	Año de la fecha de la orden
Month	int32	Mes de la fecha de la orden (numérico)
Month_Name	object	Nombre del mes (e.g., January)
Nivel_Ventas	category	Clasificación de ventas (Bajo, Medio, Alto)
Quarter	object	Trimestre del año (e.g., 2017Q4)
Region_Category	object	Combinación de región y categoría de producto
Shipping_Time	int64	Tiempo en días entre orden y envío

10. Perfilado de los datos

a. Unidad de Análisis

La granularidad original del dataset se encuentra a nivel transaccional, donde cada fila representa un producto específico dentro de una orden de compra. Sin embargo, para fines analíticos, la unidad de análisis del proyecto se centra en el desempeño de ventas por región y categoría de producto, permitiendo

identificar patrones comerciales, diferencias geográficas y tendencias de consumo.

b. Estructura del Dataset

El dataset está estructurado como un DataFrame de Pandas con **9800 filas** y **26 columnas**. Esto representa un aumento significativo en el número de columnas respecto al dataset original, lo que indica la adición de nuevas características derivadas.

Tipos de Variables

El dataset presenta una diversidad de tipos de variables, incluyendo las originales y las nuevas características:

- **Variables Numéricas (int64, float64):**
 - Row ID: Identificador único de fila (entero).
 - Sales: Monto de la venta (numérico, flotante).
 - Year: Año del pedido (entero, nueva variable derivada).
 - Month: Número del mes del pedido (entero, nueva variable derivada).
 - Shipping_Time: Tiempo de envío en días (entero, nueva variable derivada).
- **Variables Categóricas (Tipo object - cadena):**
 - Order ID, Order Date, Ship Date, Ship Mode, Customer ID, Customer Name, Segment, Country, City, State, Postal Code, Region, Product ID, Category, Sub-Category, Product Name: Estas columnas mantienen su naturaleza categórica (aunque Order Date y Ship Date serían mejor representadas como datetime para análisis, aquí se cargan como object). Es importante notar que Postal Code también aparece como object aquí.
 - Month Name: Nombre del mes (nueva variable derivada).
 - Nivel_Ventas: Nivel de ventas categorizado (nueva variable derivada).
 - Month_Name: Nombre del mes (duplicado de Month Name, nueva variable derivada).
 - Quarter: Cuarto del año (nueva variable derivada).
 - Region_Category: Combinación de Región y Categoría (nueva variable derivada).

c. Nulos

- **Estado Actual:** La verificación de `df_clean.isnull().sum()` muestra que el dataset **no contiene valores nulos** en ninguna de sus 26 columnas. Esto es un

indicativo de que el proceso de limpieza y preparación previo fue exhaustivo y que train_clean.csv es un dataset completamente poblado.

d. Observaciones de Calidad

- **Consistencia de Fechas:** Las columnas Order Date y Ship Date fueron exitosamente convertidas al tipo datetime, lo que es crucial para análisis temporales y asegura que las fechas se manejen de manera consistente.
- **Duplicados:** Se verificó que no existen filas completamente duplicadas en el dataset, lo que indica que cada registro es único en términos de todos sus atributos.
- **Cardinalidad de Categorías:** Se observaron variaciones en la cardinalidad de las variables categóricas. Por ejemplo, Country tiene un único valor, lo que sugiere que el dataset pertenece a un solo país, mientras que Order ID, Product ID, Customer ID tienen una alta cardinalidad, lo cual es esperado. Ship Mode, Segment, Category, Region y Sub-Category tienen una cardinalidad baja a media, siendo adecuadas para análisis segmentados.
- **Variabilidad en Nombres:** La alta cardinalidad en Customer Name y Product Name es esperada, pero siempre es bueno estar atento a posibles inconsistencias (ej. errores tipográficos) que podrían requerir una limpieza adicional si se desea agrupar por estos campos.
- **'Row ID' como índice único:** Row ID parece ser un identificador único para cada fila, lo cual es una buena práctica para rastrear registros individuales. Sin embargo, no se ha establecido como índice del DataFrame, lo que podría ser una optimización si fuera necesario.

e. Nuevas Características Derivadas: La inclusión de columnas como Year, Month, Month Name, Nivel_Ventas, Quarter, Region_Category, y Shipping_Time demuestra un enriquecimiento del dataset, proporcionando variables adicionales que pueden ser muy valiosas para análisis predictivos y segmentación.

- a. Shipping_Time es una métrica útil que indica la eficiencia logística.
- b. Nivel_Ventas, Quarter, Region_Category son excelentes para análisis de negocio y segmentación.

f. Variabilidad de Datos: Las estadísticas descriptivas de las columnas numéricas (Sales, Year, Month, Shipping_Time) muestran rangos y distribuciones coherentes. Sales sigue mostrando una alta variabilidad, lo cual es esperado en datos de ventas.

11. Bitácora de transformaciones

Las transformaciones realizadas aseguran la consistencia del dataset y permiten su uso en herramientas de visualización como Tableau sin ambigüedad en los tipos de datos.

Tabla 3.

Bitácora de transformaciones del data set.

Etapa	Problema detectado	Acción realizada	Resultado
-------	--------------------	------------------	-----------

Carga inicial	Columnas de fecha en formato object	Conversión de Order Date y Ship Date a datetime	Permite análisis temporal correcto
Calidad de datos	11 valores nulos en Postal Code	Reemplazo por “Desconocido”	Dataset sin valores nulos
Consistencia de texto	Inconsistencias en variables categóricas (City, State, Category, etc.)	Aplicación de strip() y title()	Estandarización de categorías
Duplicados	Posibles registros repetidos	Verificación de duplicados	No se encontraron duplicados
Feature Engineering	Falta de variables temporales	Creación de Year, Month, Month_Name, Quarter	Habilita análisis temporal
Segmentación de ventas	Necesidad de clasificación de ventas	Creación de Nivel_Ventas (Bajo, Medio, Alto)	Segmentación de rendimiento
Análisis geográfico	Falta de interacción región-categoría	Creación de Region_Category	Permite análisis cruzado
Análisis logístico	No existía métrica de envío	Cálculo de Shipping_Time	Permite análisis de tiempos de entrega
Calidad de datos	Valores extremos en Sales	Detección de outliers (IQR)	Outliers documentados (1145 casos)


12. EDA

Análisis univariado

Se examinan las distribuciones de ventas y tiempos de envío, además de las frecuencias de las principales variables categóricas “Sales” y “Shipping_Time”.


Los gráficos de distribución y boxplot permiten analizar el comportamiento estadístico de la variable Sales, identificando la concentración de valores, dispersión de los datos y presencia de valores atípicos dentro del dataset.

En primer lugar, el histograma de distribución muestra que la mayoría de las transacciones presentan montos de ventas relativamente bajos, concentrándose principalmente cerca de cero. La distribución presenta una fuerte asimetría positiva (sesgo hacia la derecha), ya que existen pocos registros con valores extremadamente altos que extienden la cola de la distribución. Esto indica que la mayor parte de las ventas corresponde a transacciones pequeñas o medianas, mientras que un número reducido de pedidos genera ingresos significativamente elevados.



Por otro lado, el boxplot confirma la existencia de una gran cantidad de valores atípicos (outliers) en la variable Sales. Se observan múltiples transacciones con montos considerablemente superiores al rango intercuartílico, alcanzando valores mayores a 20 mil dólares. Estos registros extremos representan ventas excepcionales dentro del negocio y contribuyen al sesgo observado en la distribución.

Asimismo, la concentración de datos cerca de valores bajos y la presencia de outliers sugieren que el comportamiento de las ventas no sigue una distribución normal. Este tipo de comportamiento es común en datasets comerciales y retail, donde pocas transacciones suelen generar una parte importante de los ingresos totales.



El comportamiento de la variable `Shipping_Time`, que representa la cantidad de días requeridos para realizar el envío de los pedidos. Este análisis resulta útil para comprender los patrones logísticos y la dispersión de los tiempos de entrega dentro del negocio retail.

En primer lugar, el histograma muestra que la mayor parte de los envíos se concentra entre 3 y 5 días, siendo 4 días el tiempo de envío más frecuente dentro del dataset.


Esto indica que el negocio mantiene tiempos de entrega relativamente estandarizados y consistentes para la mayoría de las transacciones.

Asimismo, se observa una distribución discreta de valores, ya que los tiempos de envío corresponden a cantidades enteras de días. Aunque existen pedidos entregados en tiempos menores o mayores, la mayoría se agrupa alrededor de valores centrales, evidenciando estabilidad en los procesos logísticos.



Por otro lado, el boxplot muestra que la mediana del tiempo de envío se encuentra aproximadamente en 4 días, mientras que el rango intercuartílico se concentra entre 3 y 5 días. Además, no se observan valores atípicos significativos, lo que indica que los tiempos de entrega presentan baja variabilidad y un comportamiento relativamente uniforme dentro del dataset.

En conjunto, el análisis evidencia que el proceso de envío del negocio mantiene tiempos de entrega controlados y consistentes, lo que podría reflejar una operación logística estable. Este tipo de información resulta relevante para evaluar eficiencia operativa, satisfacción del cliente y posibles mejoras en la cadena de distribución.




Gráficos de frecuencia



Los gráficos de frecuencia permiten analizar la distribución de los registros del dataset según diferentes variables categóricas, específicamente Segment, Category y Región. Este tipo de análisis resulta importante para comprender cómo se distribuyen las transacciones dentro del negocio retail y cuáles son los grupos con mayor participación comercial.

En primer lugar, el análisis de frecuencia por segmento de clientes muestra que el segmento Consumer concentra la mayor cantidad de registros dentro del dataset, superando ampliamente a Corporate y Home Office. Esto indica que la mayor parte de las transacciones del negocio proviene de consumidores individuales, reflejando una fuerte orientación del negocio hacia el mercado minorista. Por otro lado, Home Office presenta la menor cantidad de registros, evidenciando una participación comercial más reducida dentro del conjunto de datos.

Respecto a las categorías de productos, se observa que Office Supplies es la categoría con mayor frecuencia de transacciones, registrando la mayor cantidad de pedidos dentro del dataset. Esto sugiere que los productos de oficina poseen una demanda constante y un alto volumen de compras. En contraste, Technology presenta una menor cantidad de registros, aunque en análisis anteriores mostró mayores ingresos totales, lo que evidencia que esta categoría genera ventas de mayor valor promedio por transacción.

Finalmente, el análisis de frecuencia por región evidencia que West y East concentran la mayor cantidad de registros y actividad comercial del negocio, mientras que South presenta la menor frecuencia de pedidos. Este comportamiento coincide con los resultados obtenidos en los análisis de ventas totales, donde las regiones West y East también mostraron los mejores desempeños comerciales.





Visualizaciones de comparación

Se utilizan barplots y barras agrupadas para comparar ventas por región, categoría y combinación región-categoría.


Ventas por Región

El gráfico muestra la distribución de las ventas totales según las principales regiones geográficas del negocio: West, East, Central y South. Esta visualización permite comparar el desempeño comercial de cada región e identificar cuáles concentran mayores niveles de ingresos.

A partir del análisis, se observa que la región West registra el mayor volumen de ventas, superando ligeramente los 700 mil dólares. Esto indica que dicha región representa el principal mercado del negocio y concentra una parte importante de la actividad comercial.

De manera similar, la región East también presenta un desempeño elevado, con ventas cercanas a los 670 mil dólares, posicionándose como la segunda región más importante en términos de ingresos. Ambas regiones destacan claramente sobre Central y South, evidenciando diferencias regionales significativas en el comportamiento de las ventas.

Por otro lado, la región South muestra el menor volumen de ventas, con aproximadamente 390 mil dólares, lo que podría reflejar una menor demanda comercial, menor participación de mercado o diferencias en el comportamiento de consumo de los clientes.



Ventas por Categoría


El gráfico presenta la comparación de las ventas totales entre las principales categorías de productos del negocio retail: Technology, Furniture y Office Supplies. Esta visualización permite identificar cuáles categorías generan mayores ingresos y evaluar su importancia dentro del desempeño comercial general.

A partir del análisis, se observa que la categoría Technology registra el mayor volumen de ventas, superando los 820 mil dólares aproximadamente. Esto evidencia que los productos tecnológicos representan la principal fuente de ingresos del negocio y poseen una alta demanda dentro del mercado analizado.

Por otro lado, las categorías Furniture y Office Supplies presentan niveles de ventas relativamente similares, con valores cercanos a los 700 mil dólares. Aunque ambas mantienen un desempeño importante dentro del negocio, se encuentran por debajo de la categoría Technology en términos de generación de ingresos.

Asimismo, la diferencia de ventas entre categorías sugiere que el comportamiento de compra de los clientes se inclina significativamente hacia productos tecnológicos, lo

que podría estar relacionado con tendencias de consumo, innovación tecnológica o mayor valor promedio por transacción.



Relación entre variables

Se exploran “Sales vs Shipping_Time” con scatterplot y la matriz de correlación con heatmap.

Ventas por Región y Categoría


El gráfico compara las ventas totales entre regiones geográficas y categorías de productos, permitiendo identificar diferencias en el desempeño comercial del negocio según cada segmento analizado. Las categorías consideradas son Furniture, Office Supplies y Technology, mientras que las regiones evaluadas corresponden a Central, East, South y West.

A partir del análisis, se observa que las regiones East y West concentran los mayores niveles de ventas en casi todas las categorías, evidenciando un desempeño comercial significativamente superior respecto a Central y South. En particular, la categoría Technology presenta el mayor volumen de ventas, destacando especialmente en la región East, donde supera los 260 mil dólares aproximadamente.

Por otro lado, la región South registra consistentemente los menores niveles de ventas en las tres categorías analizadas, lo que podría indicar una menor demanda comercial o menor participación de mercado en dicha región.

Asimismo, se aprecia que la categoría Technology lidera el desempeño comercial en todas las regiones, seguida por Furniture y Office Supplies. Esto sugiere que los productos tecnológicos representan una de las principales fuentes de ingresos del negocio retail.

El análisis evidencia diferencias regionales importantes en el comportamiento de las ventas, proporcionando información relevante para estrategias comerciales, segmentación de mercado y planificación regional de inventarios y campañas promocionales.



Sales vs Shipping Time


El gráfico de dispersión muestra la relación entre el tiempo de envío (Shipping_Time) y el monto de ventas (Sales) de las transacciones registradas en el dataset. Cada punto representa una venta individual, permitiendo visualizar cómo varían las ventas según la cantidad de días requeridos para el envío del producto.

A partir del análisis, se observa que la mayoría de las ventas se concentran en valores relativamente bajos, independientemente del tiempo de envío, lo que indica una alta dispersión de los datos y ausencia de una relación lineal clara entre ambas variables. Esto sugiere que el tiempo de entrega no influye significativamente en el monto de ventas generado por una transacción.

Asimismo, se identifican algunos valores atípicos (outliers) con montos de ventas considerablemente elevados, especialmente en tiempos de envío entre 2 y 7 días. Sin embargo, estos casos son aislados y no representan una tendencia general dentro del comportamiento del dataset.

El análisis también evidencia que los tiempos de envío más frecuentes se encuentran entre 2 y 5 días, concentrando gran parte de las transacciones comerciales del negocio. Esto podría reflejar políticas logísticas estandarizadas o preferencias operativas de distribución.

En conjunto, los resultados indican que las ventas del negocio dependen más de factores comerciales y segmentaciones estratégicas (como región, categoría de producto o temporalidad) que del tiempo de envío en sí mismo.




Heatmap de correlación entre variables numéricas

El heatmap de correlación muestra el grado de relación lineal entre las principales variables numéricas del dataset: **Sales, Year, Month y Shipping_Time**. Los valores de correlación oscilan entre -1 y 1, donde valores cercanos a 1 indican una relación positiva fuerte, valores cercanos a -1 indican una relación negativa fuerte y valores próximos a 0 representan ausencia de correlación significativa.

A partir del análisis, se observa que las correlaciones entre las variables son extremadamente bajas, ya que la mayoría de los coeficientes se encuentran muy cerca de cero. Por ejemplo, la relación entre Sales y Shipping_Time presenta una correlación de aproximadamente -0.01, lo que indica que el tiempo de envío no tiene un impacto lineal significativo sobre las ventas. De manera similar, las variables temporales Year y Month tampoco muestran relaciones fuertes con el comportamiento de las ventas.

Estos resultados sugieren que el desempeño comercial del negocio no depende de una única variable numérica aislada, sino probablemente de factores categóricos y segmentaciones más complejas, como región geográfica, categoría de producto o patrones estacionales.

Asimismo, la ausencia de correlaciones elevadas indica que no existe multicolinealidad significativa entre las variables numéricas analizadas, lo que favorece la estabilidad de futuros análisis estadísticos o modelos analíticos complementarios.



Tendencia temporal

Se analiza el comportamiento de las ventas por mes y por trimestre utilizando line charts y barras.


Ventas por Quarter

El gráfico muestra la evolución de las ventas totales agrupadas por trimestre entre los años 2015 y 2018. Esta visualización permite identificar patrones estacionales y variaciones en el desempeño comercial del negocio a lo largo del tiempo.

A partir del análisis, se observa que el cuarto trimestre (Q4) presenta consistentemente los niveles más altos de ventas en todos los años analizados. Este comportamiento es especialmente evidente en 2017 y 2018, donde las ventas superan los 230 mil y 270 mil dólares respectivamente. Esto sugiere la existencia de una fuerte estacionalidad comercial asociada al cierre de año, campañas promocionales y aumento del consumo durante temporadas festivas.

Asimismo, los primeros trimestres (Q1) muestran valores significativamente menores en comparación con Q3 y Q4, indicando periodos de menor actividad comercial. Sin embargo, se aprecia una tendencia general de crecimiento progresivo de las ventas entre 2015 y 2018, reflejando una expansión del desempeño del negocio a lo largo del tiempo.

Este comportamiento trimestral resulta relevante para la toma de decisiones estratégicas, ya que permite anticipar periodos de alta demanda y optimizar procesos relacionados con inventario, planificación comercial y estrategias de marketing.



Heatmap Ventas por región y categoría


El gráfico de “**Ventas por región y categoría**” presenta la distribución de las ventas totales según la combinación entre región geográfica y categoría de producto. Este tipo de visualización permite identificar rápidamente patrones de desempeño comercial mediante la intensidad de color, donde los tonos más oscuros representan mayores niveles de ventas.

A partir del análisis, se observa que las regiones West y East concentran los mayores volúmenes de ventas en casi todas las categorías de productos. En particular, la categoría Technology destaca como la de mejor desempeño comercial, alcanzando su valor máximo en la región East con aproximadamente 263 mil dólares en ventas, seguida de la región West con cerca de 247 mil dólares.

Por otro lado, la región South presenta consistentemente los menores niveles de ventas en las tres categorías analizadas, especialmente en Furniture y Office Supplies. Esto evidencia diferencias regionales significativas en el comportamiento comercial del negocio.

Asimismo, se aprecia que la categoría Technology mantiene un desempeño superior respecto a Furniture y Office Supplies en la mayoría de regiones, lo que sugiere una

mayor demanda o rentabilidad asociada a productos tecnológicos dentro del negocio retail.




Ventas totales mensuales a lo largo del tiempo

El gráfico de “**Ventas totales mensuales en el tiempo**” muestra la evolución de las ventas mensuales totales del negocio entre los años 2015 y 2018 mediante una combinación de barras y línea de tendencia. Las barras representan el monto total de ventas por mes, mientras que la línea roja facilita la identificación de patrones temporales y variaciones en el comportamiento comercial.

A partir del análisis, se observa que las ventas presentan fluctuaciones significativas a lo largo del tiempo, evidenciando patrones estacionales en determinados periodos del año. Los valores más altos de ventas se concentran principalmente hacia el último trimestre de cada año, especialmente entre septiembre y noviembre, lo que sugiere un incremento de la actividad comercial asociado a campañas estacionales, promociones o mayor demanda en fechas de cierre anual.

Asimismo, se aprecia una tendencia general de crecimiento progresivo en las ventas desde 2015 hasta 2018. El año 2018 registra los mayores niveles de ventas mensuales, alcanzando un pico cercano a los 120 mil dólares en noviembre de 2018, lo que evidencia una expansión del desempeño comercial del negocio durante el periodo analizado.

Por otro lado, los meses iniciales de cada año muestran valores relativamente menores, indicando posibles periodos de baja demanda o estacionalidad negativa. Este comportamiento temporal resulta relevante para la toma de decisiones relacionadas con planificación comercial, gestión de inventarios y estrategias de ventas.



13. Insights

Insight 1 : Las regiones West y East impulsan el desempeño comercial del negocio

El análisis regional mostró que las regiones West y East concentran los mayores niveles de ventas en casi todas las categorías de productos, especialmente en Technology. Esto evidencia diferencias geográficas significativas en el comportamiento comercial del negocio, donde determinadas regiones presentan una mayor demanda y capacidad de generación de ingresos. Estos resultados pueden utilizarse para orientar estrategias de expansión, distribución de inventarios y campañas comerciales focalizadas en las regiones con mayor potencial de crecimiento.

Insight 2 : La categoría Technology presenta el mayor impacto en las ventas

La categoría Technology registró consistentemente los mayores volúmenes de ventas en comparación con Furniture y Office Supplies, particularmente en las regiones East y West. Aunque Office Supplies posee una mayor frecuencia de transacciones, Technology genera un mayor valor promedio por venta, convirtiéndose en la categoría más rentable dentro del negocio retail. Este comportamiento sugiere que el negocio podría priorizar inversiones, promociones y estrategias de fidelización enfocadas en productos tecnológicos para maximizar ingresos y rentabilidad.

Insight 3 : Las ventas presentan patrones estacionales durante el cuarto trimestre

El análisis temporal evidenció que las ventas alcanzan sus niveles más altos durante el cuarto trimestre de cada año, especialmente entre septiembre y diciembre. Este patrón estacional se intensifica en 2017 y 2018, donde se registran los mayores picos de ventas del periodo analizado. Esto sugiere que factores como campañas promocionales, temporadas festivas y aumento del consumo influyen directamente en el desempeño comercial de las categorías. Estos hallazgos permiten anticipar periodos de alta demanda y apoyar decisiones relacionadas con planificación de inventarios, estrategias de marketing y asignación de recursos comerciales.

Insight 4 : La frecuencia de transacciones no siempre implica mayores ingresos

El análisis de frecuencia mostró que la categoría Office Supplies registra la mayor cantidad de pedidos dentro del dataset; sin embargo, la categoría Technology genera mayores niveles de ventas totales. Esto evidencia que un mayor volumen de transacciones no necesariamente se traduce en mayores ingresos, ya que los productos tecnológicos presentan un valor promedio por venta considerablemente superior. Este comportamiento puede utilizarse para priorizar estrategias enfocadas en productos de alto valor y maximizar la rentabilidad del negocio.

Insight 5 : Los tiempos de envío presentan estabilidad y baja influencia sobre las ventas

El análisis de Shipping_Time mostró que la mayoría de los pedidos se entregan entre 3 y 5 días, evidenciando un proceso logístico relativamente estable y consistente. Además, el análisis de correlación y el gráfico de dispersión entre ventas y tiempo de envío mostraron una relación prácticamente nula entre ambas variables. Esto sugiere que el desempeño de las ventas depende principalmente de factores comerciales y segmentaciones regionales más que del tiempo de entrega, permitiendo que las estrategias del negocio se enfoquen prioritariamente en categorías, regiones y temporalidad de ventas.

14. Gráficos descartados

Durante el proceso de análisis exploratorio y diseño del dashboard, se evaluaron distintos tipos de visualizaciones. Sin embargo, algunos gráficos fueron descartados debido a limitaciones relacionadas con legibilidad, interpretación y capacidad analítica.

Gráfico descartado	Razón del descarte
Pie Chart (gráfico circular) para categorías y regiones	Fue descartado porque la comparación entre múltiples categorías y regiones resultaba poco clara visualmente. Además, las diferencias de tamaño entre segmentos dificultaban la interpretación precisa de los valores y patrones comerciales.
Gráfico de barras 3D	Se descartó debido a que la perspectiva tridimensional distorsionaba la percepción de las magnitudes y dificultaba la comparación entre categorías y regiones. Este tipo de gráfico reducía la claridad visual y afectaba la legibilidad del dashboard.

Los gráficos finalmente seleccionados, como barplots, heatmaps y line charts, ofrecieron una representación más clara y efectiva de los datos, permitiendo identificar patrones temporales, diferencias regionales y relaciones entre categorías de manera más intuitiva y analítica.

15. Reglas de Métricas, Segmentos y Parámetros

15.1. Estructura analítica para Tableau

El dataset `train_clean.csv` mantiene granularidad transaccional (1 fila = 1 producto dentro de una orden). A partir de él se generaron tablas agregadas complementarias, todas derivadas mediante `groupby` sin introducir duplicación de registros base.

Validación de cardinalidad: se verificó que el número de filas de `resumen_region_category_quarter.csv` coincide exactamente con el número de combinaciones únicas de `Region × Category × Year × Quarter` en el dataset original, y que la suma de `Total_Sales` agregada es idéntica a la suma de `Sales` en el dataset base. Esto confirma que no hay pérdida ni duplicación de información en el proceso de agregación.

Todas las tablas comparten las claves `Region`, `Category`, `Year` y/o `Quarter`, lo que permite relacionarlas en Tableau mediante *relationships* (no joins físicos) sin generar explosión de filas (fan-out).

15.2. Segmento definido

15.2.1. Segmento principal: `Region_Category`

Variable categórica existente (combinación de `Region` + `Category`, ej. "West - Technology") que permite segmentar el análisis comercial cruzando dimensión geográfica y de producto. Es la base de las vistas comparativas transversales del dashboard.

15.2.2. Segmento complementario: Quarter_Label

Derivado de Quarter extrayendo solo el trimestre (Q1-Q4, sin año), permite analizar estacionalidad de forma independiente al año, respondiendo directamente a la Hipótesis 1 del proyecto (patrones estacionales recurrentes).

15.3. Métricas derivadas y su relación con la pregunta analítica

Métrica	Archivo	Cálculo	Relación con la pregunta analítica
Pct_Participacion_Categoria	resumen_region_category_quarter.csv	% que representa cada categoría dentro de su región/periodo	Permite comparar el peso relativo de cada categoría por región, más allá del volumen absoluto clave para decisiones de mix de inventario
Ventas_Acumuladas	ventas_acumuladas_anual.csv	Suma acumulada trimestral dentro de cada año	Visualiza la velocidad de acumulación de ingresos y permite identificar si la concentración en Q4 (estacionalidad) acelera el cierre de año
YoY_Growth_Pct	yoy_growth_categoria.csv	Variación % de ventas respecto al año anterior, por categoría	Responde directamente a la Hipótesis 4 (tendencias de crecimiento/decrecimiento por periodo)
Ranking (regiones)	ranking_regiones.csv	Orden descendente de regiones por ventas totales	Apoya el Insight 1 (West/East como motores comerciales) y habilita el parámetro Top N
Avg_Sales por Quarter_Label	estacionalidad_categoria.csv	Promedio de ventas por trimestre (sin año), por categoría	Aísla el efecto estacional puro, sin la tendencia de crecimiento interanual

15.3.1. Nota sobre valores nulos esperados: YoY_Growth_Pct presenta NaN para el año 2015 en las tres categorías, dado que no existe un año previo (2014) con el cual calcular la variación. Esto es matemáticamente correcto y se documenta para evitar interpretarlo como un error de procesamiento.

15.4. Parámetros y lógica analítica para Tableau

- Año Seleccionado (parámetro entero: 2015–2018 + "Todos"): filtra las vistas temporales y habilita comparaciones año contra año.
- Métrica a Visualizar (parámetro de cadena: Ventas Totales / % Participación / Ticket Promedio): permite alternar la medida mostrada en un mismo gráfico sin duplicar hojas.
- Top N (parámetro entero: 3, 5, 10): controla cuántas regiones/categorías se muestran en vistas de ranking.

15.4.1. Cálculo LOD implementado:

{ FIXED [Region] : SUM([Sales]) } para obtener el total de ventas por región independientemente de los filtros activos en el dashboard, usado como denominador del % de participación. Este cálculo es el equivalente nativo en Tableau de Pct_Participacion_Categoria, y se mantiene ambos: el pre-calculado en Python (para consistencia y trazabilidad del pipeline) y el LOD en Tableau (para flexibilidad ante filtros interactivos del usuario).

15.5. Fuentes finales para Tableau

Ubicación: data/processed/

- train_clean_enriched.csv — dataset base con Quarter_Label añadido
- resumen_region_category_quarter.csv
- ventas_acumuladas_anual.csv
- yoy_growth_categoria.csv
- ranking_regiones.csv
- estacionalidad_categoria.csv

Todos los archivos tienen tipos de datos consistentes (fechas como string ISO, numéricos sin notación científica) y claves de relación compartidas, por lo que pueden conectarse a Tableau sin necesidad de reprocesamiento manual de tipos o nombres de columna.

15.6. Evidencia de validación ejecutada

Se ejecutó la validación de integridad sobre las 5 tablas agregadas, confirmando:

- Suma total de Sales (dataset original): \$2,261,536.78

- resumen_region_category_quarter: 192 filas (= combinaciones únicas Region×Category×Year×Quarter), suma coincide
- ventas_acumuladas_anual: 16 filas, suma sin acumular coincide, último acumulado = suma del año
- yoy_growth_categoria: 12 filas, suma coincide, 3 NaN esperados (año 2015)
- ranking_regiones: 4 filas (una por región), suma coincide
- estacionalidad_categoria: 12 filas (4 quarters × 3 categorías)

Todas las validaciones resultaron exitosas, confirmando que no existe duplicación ni pérdida de información en el proceso de agregación.

16. Conclusiones

- **Sobre la estructura y validación de datos**

El proceso de transformación de la unidad de análisis transaccional hacia la unidad Región-Categoría se ejecutó sin pérdida ni duplicación de información. Las cinco tablas agregadas generadas (resumen por región-categoría-periodo, ventas acumuladas, crecimiento interanual, ranking regional y estacionalidad) fueron validadas exhaustivamente, confirmando que cada una conserva la consistencia total de \$2,261,536.78 en ventas respecto al dataset original. Esto garantiza que cualquier visualización construida sobre estas fuentes en Tableau será fiel a los datos transaccionales reales.

- **Sobre las métricas y su utilidad analítica**

Las métricas derivadas no fueron seleccionadas de forma arbitraria, sino que cada una responde directamente a una hipótesis o insight previamente identificado en el EDA:

- El % de participación por categoría permite profundizar en el Insight 4 (frecuencia vs. valor de transacción).
- Las ventas acumuladas y la estacionalidad por trimestre operacionalizan la Hipótesis 1, separando el efecto estacional puro del efecto de crecimiento anual.
- El crecimiento YoY confirma cuantitativamente la Hipótesis 4, mostrando una recuperación marcada en 2017 tras una contracción en 2016 en Office Supplies y Technology.
- El ranking regional traduce el Insight 1 en un componente interactivo (parámetro Top N).

- **Sobre la segmentación**

La definición de Region_Category como segmento principal y Quarter_Label como segmento temporal complementario asegura que el dashboard final pueda abordar

tanto la dimensión geográfica-comercial como la estacional de forma independiente, evitando que ambos efectos se confundan en una sola vista.

- **Sobre la preparación para Tableau**

Al combinar cálculos pre-procesados en Python (para trazabilidad y reproducibilidad del pipeline) con un cálculo LOD nativo en Tableau (para flexibilidad ante filtros del usuario), el proyecto demuestra dominio de ambas aproximaciones, cumpliendo con el requisito de incorporar lógica analítica avanzada sin sacrificar la auditabilidad del proceso.

17. Referencias

Sahoo, R. (2020). Superstore Sales Dataset. Kaggle. Recuperado 11 de abril de 2026, de <https://www.kaggle.com/datasets/rohitsahoo/sales-forecasting>

Anexos

Anexo A.

Link del repositorio del Github : https://github.com/SofiaGMiranda/proyect_dv.git